

**CENTRO UNIVERSITÁRIO NHANES_VISION
CURSO DE ENGENHARIA DE SOFTWARE E
INTELIGÊNCIA ARTIFICIAL**

**DESENVOLVIMENTO DE APLICAÇÃO DE INTELIGÊNCIA
ARTIFICIAL PARA O DIAGNÓSTICO E PREDIÇÃO DA
SEVERIDADE DA MIOPIA COM BASE EM DADOS
BIOMÉTRICOS E DEMOGRÁFICOS DO NHANES**

**PROPOSTA DE TRABALHO DE CONCLUSÃO DE CURSO
(TCC)**

Autor: Projeto NHANES_vision

**Cidade de Origem
2026**

Projeto NHANES_vision

DESENVOLVIMENTO DE APLICAÇÃO DE INTELIGÊNCIA ARTIFICIAL PARA O DIAGNÓSTICO E PREDIÇÃO DA SEVERIDADE DA MIOPIA COM BASE EM DADOS BIOMÉTRICOS E DEMOGRÁFICOS DO NHANES

Trabalho de Conclusão de Curso (TCC) apresentado ao Centro Universitário NHANES_vision como requisito parcial para obtenção do título de Bacharel em Inteligência Artificial e Ciência de Dados.

Área de Concentração: Aprendizado de Máquina,

Epidemiologia Ocular e Biometria Humana.

Orientador: Prof. Dr. Orientador Acadêmico

Cidade de Origem

2026

RESUMO

A miopia representa um dos maiores desafios de saúde pública global do século XXI, com um crescimento acelerado de prevalência que não pode ser explicado puramente por fatores genéticos. Este trabalho apresenta a fundamentação teórica e a metodologia para o desenvolvimento de uma aplicação de Inteligência Artificial baseada no repositório público `NHANES_vision`, utilizando dados demográficos e de exames de visão do National Health and Nutrition Examination Survey (NHANES 2005-2006). A aplicação tem como propósito classificar a presença e a severidade da miopia (leve, moderada e alta) e regredir de forma contínua o equivalente esférico refrativo (SE) dos pacientes. A fundamentação teórica revisa detalhadamente as evidências científicas que correlacionam a miopia com fatores nutricionais (como os níveis séricos de Vitamina D), biométricos (como o Índice de Massa Corporal e gordura corporal total), estresse oxidativo (através do Oxidation Balance Score) e covariáveis demográficas (idade e sexo). A metodologia delineia o pipeline de dados desenvolvido em Python utilizando as bibliotecas `pandas`, `numpy`, `scikit-learn`, `xgboost` e `imbalanced-learn` para tratamento de desbalanceamento de classes, engenharia de atributos e modelagem preditiva por meio de classificação e regressão. Como o projeto está em sua fase inicial de estruturação de código, os resultados e discussões estão sinalizados como em construção. Este documento fornece a base de validação científica necessária para prosseguir com a implementação computacional do sistema de diagnóstico inteligente.

Palavras-chave: Miopia; Inteligência Artificial; NHANES; Machine Learning; Equivalente Esférico; Biometria Ocular.

Sumário

1	Introdução	5
2	Referencial Teórico	7
2.1	Fatores Nutricionais e Hormonais: O Papel da Vitamina D e da Insulina .	7
2.2	Fatores Antropométricos e Obesidade	8
2.3	Estresse Oxidativo e Algoritmos de Seleção de Atributos	8
2.4	Fatores Genéticos e Variáveis Demográficas	9
3	Metodologia	10
3.1	Fonte e Aquisição dos Dados	10
3.2	Variável Alvo: Equivalente Esférico (SE)	10
3.3	Dependências Tecnológicas do Projeto	11
3.4	Pipeline de Engenharia de Atributos e Modelagem	12
4	Resultados	14
5	Discussão	14
6	Considerações Finais	14
	Referências	15

1 Introdução

A miopia é uma anomalia refrativa de relevância epidemiológica global, caracterizada pela focalização de imagens de objetos distantes em uma região anterior à retina, o que resulta em visão embaçada para longe. O rápido crescimento da prevalência de miopia e alta miopia nas últimas décadas consolidou o distúrbio como uma preocupação de saúde pública mundial no século XXI. Projeta-se que até o ano de 2050, cerca de metade da população global será míope, o que trará significativas implicações socioeconômicas e prejuízos de produtividade devido à perda visual não corrigida ou a complicações patológicas severas associadas.

Esse aumento exponencial não pode ser atribuído exclusivamente a fatores de predisposição genética familiar, o que tem motivado intensas investigações na literatura científica sobre a influência de fatores ambientais, antropométricos, de estilo de vida e nutricionais no desenvolvimento e progressão dessa patologia. Estudos epidemiológicos sugerem que uma gama complexa de determinantes sistêmicos desempenha um papel na etiologia da miopia. Entre esses fatores, destacam-se a deficiência de Vitamina D decorrente de baixa exposição à radiação ultravioleta B (UVB) em atividades ao ar livre, a relação com o desenvolvimento ponderal e a obesidade, o estresse oxidativo sistêmico e as disparidades demográficas tradicionais (como idade, sexo e fatores socioeconômicos).

Paralelamente, a ascensão da Inteligência Artificial (IA) e do Aprendizado de Máquina (Machine Learning) na medicina abriu novas frentes para a triagem e diagnóstico automatizado de patologias oculares. Algoritmos preditivos avançados são capazes de capturar interações complexas e não lineares entre múltiplos atributos biométricos e demográficos, oferecendo uma ferramenta altamente acurada e escalável para auxiliar clínicos no diagnóstico precoce e no monitoramento de erros refrativos.

O repositório público `NHANES_vision` visa o desenvolvimento de uma aplicação de Inteligência Artificial para diagnóstico e predição da miopia fundamentada em dados do National Health and Nutrition Examination Survey (NHANES). Especificamente, este trabalho propõe-se a estruturar as bases conceituais e metodológicas do projeto utilizando dados demográficos (Demographics Data) e de exames oftalmológicos (Examination Data) do ciclo NHANES de 2005-2006. O sistema proposto implementará duas tarefas principais de aprendizado de máquina em linguagem Python:

1. **Classificação Multiclasse:** Classificar o grau de erro refrativo em categorias clinicamente relevantes, identificando indivíduos sem miopia, com miopia leve/moderada ou com alta miopia.
2. **Regressão Contínua:** Estimar numericamente o equivalente esférico refrativo (SE - *Spherical Equivalent Refractive Error*) em dioptrias (D), fornecendo uma avaliação

quantitativa da severidade ocular.

Dada a fase inicial do desenvolvimento do repositório, na qual os códigos de treinamento e teste dos modelos preditivos ainda não foram executados, os capítulos dedicados à apresentação de resultados e discussões científicas do modelo final de IA constam temporariamente como em construção neste documento de Trabalho de Conclusão de Curso (TCC).

2 Referencial Teórico

A modelagem de modelos de Inteligência Artificial para diagnóstico oftálmico necessita de uma sólida fundamentação biomédica para a seleção apropriada de variáveis preditivas. Esta seção revisa a literatura científica grounded nas pesquisas epidemiológicas do NHANES e KNHANES para demonstrar a validade das variáveis selecionadas no projeto.

2.1 Fatores Nutricionais e Hormonais: O Papel da Vitamina D e da Insulina

A hipótese de que a exposição solar previne o aparecimento de miopia tem sido fortemente correlacionada com a síntese de vitamina D na pele por meio de radiação UVB. Wolf et al. (2024), ao analisarem uma amostra representativa de 11.669 participantes com idades entre 12 e 50 anos do banco de dados do NHANES (2001-2006), demonstraram que indivíduos diagnosticados com miopia (definida formalmente como equivalente esférico $\leq -1,0$ dioptria) apresentavam concentrações séricas médias de vitamina D significativamente menores do que os indivíduos não míopes ($61,6 \pm 0,9$ nmol/L contra $63,1 \pm 0,8$ nmol/L, com valor de $p = 0,01$).

A análise multivariada de regressão logística de Wolf et al. (2024), após ajustar para fatores de confusão como sexo, idade, etnia, nível de escolaridade, níveis de vitamina A sérica e índice de pobreza, evidenciou que concentrações séricas mais elevadas de vitamina D estavam fortemente associadas a uma menor probabilidade de ocorrência de miopia (Odds Ratio de 0,82; IC 95%: 0,74-0,92; $p = 0,0007$). Ademais, um modelo de regressão linear que excluiu participantes hipermetropes ($SE > +1,0$ D) revelou uma relação de dose-resposta positiva: à medida que os níveis de vitamina D sérica dobravam, o equivalente esférico refrativo aumentava em 0,17 dioptria ($p = 0,02$), indicando uma mudança em direção à emetropização (redução da miopia).

Embora Harb e Wildsoet (2021) tenham analisado uma coorte menor de 6.855 americanos de 12 a 25 anos (ciclos NHANES de 2003 a 2008) e tenham observado correlações diretas fracas para vitamina D no modelo multivariado final de sua pesquisa específica, o estudo identificou outro fator nutricional e endócrino relevante: níveis elevados de insulina em jejum apresentaram associação significativa com o aumento das chances de ocorrência de miopia em jovens. Essa constatação levanta a hipótese de que caminhos metabólicos relacionados à resistência insulínica e dietas hiperglicêmicas podem interagir com os mecanismos de sinalização do crescimento ocular e escleral, sugerindo a importância de mapear variáveis de controle metabólico nas análises de risco.

2.2 Fatores Antropométricos e Obesidade

A relação entre indicadores ponderais (como Índice de Massa Corporal - IMC, percentual de gordura e circunferência da cintura) e erros refrativos tem sido estudada por meio de levantamentos populacionais, revelando conexões importantes. Lee et al. (2022) conduziram um estudo transversal com 1.114 crianças e adolescentes (5 a 18 anos) a partir dos dados do KNHANES VII (2016-2018). Embora a obesidade e o sobrepeso não tenham se associado estatisticamente ao desenvolvimento de miopia leve ou moderada, o estudo revelou um impacto expressivo na prevalência de **alta miopia** (equivalente esférico $\leq -6,0$ dioptrias).

Em comparação com o grupo de peso normal, as chances de desenvolver alta miopia aumentaram progressivamente nos grupos de maior percentil de IMC: o Odds Ratio ajustado para o grupo obeso (definido como IMC $\geq$ percentil 95) foi de 3,77 (IC 95%: 1,98-7,16). Na análise estratificada por sexo, meninos obesos apresentaram um OR de 2,84 (IC 95%: 1,10-7,35), enquanto meninas apresentaram riscos ainda maiores: OR de 4,23 (IC 95%: 1,19-15,09) no grupo com sobrepeso e 5,04 (IC 95%: 1,77-14,34) no grupo obeso. Esses achados apoiam fortemente a teoria de que desregulações sistêmicas associadas à obesidade infantil afetam negativamente as propriedades de desenvolvimento biométrico do olho.

Em adultos, Noh e Jung (2024) analisaram uma coorte representativa de 10.305 participantes maiores de 19 anos a partir dos dados do KNHANES (2008-2010), utilizando absorciometria de raios-X de dupla energia (DXA) para a medição direta da porcentagem de gordura corporal total. Os autores constataram que os indivíduos com miopia possuíam maiores índices de obesidade após ajustes estatísticos rigorosos. Verificou-se que adultos posicionados no quarto quartil de percentual de gordura corporal possuíam maiores chances de apresentar miopia, exibindo um OR ajustado de 1,352 (IC 95%: 1,178-1,551). Curiosamente, essa associação foi de extrema relevância estatística na coorte de jovens adultos (19 a 39 anos, $p < 0,05$), perdendo significância no grupo de meia-idade e idosos, o que salienta a necessidade de incluir termos de interação entre idade e índices de adiposidade nos algoritmos preditivos de IA.

2.3 Estresse Oxidativo e Algoritmos de Seleção de Atributos

A literatura científica recente começou a explorar a relação entre o balanço redox do organismo e a fisiopatologia ocular. Wu et al. (2024) investigaram o impacto do Índice de Balanço Oxidativo (Oxidation Balance Score - OBS), um marcador sistêmico composto por fatores dietéticos e de estilo de vida pró-oxidantes e antioxidantes, na ocorrência e gravidade da miopia em 5.187 participantes do NHANES 2007-2008.

O estudo encontrou uma associação estatisticamente relevante do OBS com a miopia exclusivamente em adultos com idade igual ou superior a 20 anos ($N = 4.253$). Observou-se uma relação linear direta entre a elevação do OBS (caracterizada por um perfil mais exposto a desequilíbrios antioxidantes e pró-oxidantes específicos) e a ocorrência do erro refrativo (OR: 1,01; IC 95%: 1,00-1,02). Além disso, análises de regressão logística ordenada demonstraram que para cada unidade de incremento no score OBS, a probabilidade de aumento na severidade da miopia elevava-se em 11% ($p < 0,01$).

De particular importância para o desenvolvimento de sistemas inteligentes, Wu et al. (2024) aplicaram técnicas de aprendizado de máquina baseadas em árvores de decisão, incluindo **XGBoost**, **Random Forest** e **AdaBoost**, para identificar a importância relativa dos constituintes individuais do OBS. O XGBoost e as outras arquiteturas revelaram que o consumo e os níveis de cálcio representavam o elemento de maior importância dentro do score OBS na associação com a incidência e gravidade de miopia nos participantes, indicando um papel em potencial da sinalização intracelular de cálcio no desenvolvimento da esclera.

2.4 Fatores Genéticos e Variáveis Demográficas

Historicamente, a hereditariedade é reconhecida como um componente importante na determinação ocular. Lim et al. (2018) estudaram 3.862 crianças de 5 a 18 anos provenientes de 2.344 famílias incluídas no KNHANES IV e V (2008-2012) para elucidar a contribuição do erro refrativo dos pais sobre a manifestação miópica dos filhos. A prevalência de miopia infantil foi alta, atingindo 64,6%, das quais 5,4% representavam casos de alta miopia.

Os autores demonstraram que a razão de prevalência ajustada (PRR) para miopia e alta miopia pediátrica quando os pais eram míopes foi de 1,34 (IC 95%: 1,24-1,45) e 3,11 (IC 95%: 1,93-5,01), respectively. O risco relativo de miopia escalou drasticamente à medida que o grau de miopia dos pais se intensificava, alcançando um PRR de 11,41 (IC 95%: 6,24-20,88) para alta miopia em crianças cujos pais possuíam alto grau refrativo de miopia ($p < 0,001$). Adicionalmente, o estudo confirmou que variáveis como a idade da criança e a renda familiar mensal eram preditores altamente significativos de todas as faixas de severidade de miopia.

Dessa forma, a análise literária comprova que a idade do paciente, o sexo biológico, os níveis metabólicos de micronutrientes (Vitamina D, cálcio), indicadores antropométricos de adiposidade (IMC, percentual de gordura por DXA) e variáveis socioeconômicas (como renda e nível educacional) constituem um conjunto de atributos robusto para a inicialização do desenvolvimento de modelos preditivos.

3 Metodologia

Este capítulo descreve a proposta de arquitetura de dados e de modelagem preditiva baseada no repositório público `NHANES_vision`, especificando o pipeline tecnológico, a origem dos dados e a estruturação das tarefas em Python.

3.1 Fonte e Aquisição dos Dados

Os dados utilizados neste projeto provêm do banco de dados público do National Health and Nutrition Examination Survey (NHANES) do ciclo 2005-2006. O NHANES é conduzido pelo National Center for Health Statistics (NCHS) dos Estados Unidos e baseia-se em um plano de amostragem complexo de múltiplos estágios para gerar estatísticas nacionalmente representativas sobre a saúde e o estado nutricional da população civil não institucionalizada.

A aplicação baseia-se na fusão de dois conjuntos primários de dados:

1. **Dados Demográficos (Demographics Data):** Contêm as informações sociodemográficas cruciais, tais como idade do participante (em anos completos), sexo biológico, raça/etnia autodeclarada, nível educacional máximo alcançado e a relação de renda familiar frente à linha de pobreza nacional.
2. **Dados de Exames Oficiais (Examination Data - Vision):** Contêm os registros de exames físicos oftalmológicos coletados por meio de testes automatizados de refratometria e acuidade visual. Nesses dados residem as medições físicas do erro refrativo, fundamentais para o cálculo da variável alvo.

3.2 Variável Alvo: Equivalente Esférico (SE)

A variável chave para o treinamento supervisionado dos modelos é o Equivalente Esférico (SE - *Spherical Equivalent Refractive Error*). Clinicamente, o SE é calculado de forma padronizada para cada olho separadamente, somando-se o componente esférico com metade do componente cilíndrico medidos em dioptrias:

$$SE = \text{Esfera} + \frac{\text{Cilindro}}{2} \quad (1)$$

A partir do valor contínuo do SE obtido em dioptrias para o olho dominante do participante, estabelecem-se duas abordagens de modelagem preditiva distintas na aplicação:

1. **Modelagem Regressiva (Severidade Contínua):** O valor numérico contínuo do SE atua diretamente como o target $y_{reg} \in \mathbb{R}$. Modelos de regressão buscam

minimizar o erro quadrático na estimativa do poder de refração do olho.

2. **Modelagem Classificatória (Severidade Discreta):** O valor do SE é mapeado em classes discretas baseadas nos critérios epidemiológicos padrão estabelecidos na literatura médica:

- **Não Míope (Normal/Hipermetrope):** $SE > -0,5$ D.
- **Miopia Leve a Moderada:** $-6,0 \text{ D} < SE \leq -0,5$ D.
- **Alta Miopia:** $SE \leq -6,0$ D.

Dessa forma, o target classificatório $y_{class} \in \{0, 1, 2\}$ representa o grau discreto da miopia.

3.3 Dependências Tecnológicas do Projeto

Para garantir reprodutibilidade, eficiência computacional e facilidade de deploy, a aplicação foi estruturada utilizando a linguagem de programação Python (versão ≥ 3.12) e um ecossistema robusto de bibliotecas open-source listado a seguir:

- **pandas** (≥ 2.2): Essencial para a leitura dos arquivos originais em formato XPT do NHANES, mesclagem eficiente dos dataframes de demografia e exames através do identificador único de participante (**SEQN**) e etapas iniciais de limpeza e tratamento de valores ausentes.
- **numpy** (≥ 1.26): Utilizado para operações matemáticas de alto desempenho e vetorização de cálculos biométricos (como o cálculo do SE).
- **matplotlib** (≥ 3.8) e **seaborn** (≥ 0.13): Ferramentas empregadas na Análise Exploratória de Dados (EDA) para plotagem de histogramas de distribuição do erro refrativo, diagramas de dispersão cruzada entre idade/IMC e SE, e mapas de calor de correlações lineares.
- **scikit-learn** (≥ 1.5): Framework que fornece todo o suporte ao pipeline de modelagem, englobando funções de partição dos dados em conjuntos de treino e teste (**train_test_split**), pré-processadores como imputação de dados nulos (**SimpleImputer**), padronização de variáveis numéricas (**StandardScaler**), codificação de atributos categóricos (**OneHotEncoder**) e algoritmos base como Regressão Linear, Regressão Logística e Random Forest.
- **xgboost** (≥ 2.1): Implementação de árvores de decisão impulsionadas por gradiente (Gradient Boosting), selecionada pela sua robustez frente a dados tabulares e habilidade em capturar interações complexas sem sobreajustamento excessivo.

- **imbalanced-learn** (≥ 0.12): Uma biblioteca auxiliar crucial para mitigar o severo desbalanceamento de classes inerente aos dados populacionais, onde a incidência de alta miopia representa uma fração minoritária (e.g., cerca de 5% em relação aos indivíduos normais ou com miopia leve). O pacote disponibiliza técnicas de sobreamostragem sintética como o SMOTE (*Synthetic Minority Over-sampling Technique*).
- **joblib** (≥ 1.4): Utilizado para serialização eficiente e persistência em disco dos modelos treinados e escaladores de pré-processamento, viabilizando o deploy subsequente em sistemas de produção.
- **jupyter** (≥ 1.0) e **ipykernel** (≥ 6.29): Ambientes de desenvolvimento interativos recomendados para o desenvolvimento ágil das análises exploratórias iniciais e prototipação rápida dos algoritmos.

3.4 Pipeline de Engenharia de Atributos e Modelagem

O fluxo de processamento de dados proposto para a aplicação estruturar-se-á conforme as etapas detalhadas a seguir:

1. **Ingestão e Mesclagem:** Leitura dos dados de demografia e oftalmologia do NHANES 2005-2006. Junção interna baseada no identificador de participante `SEQN`.
2. **Filtragem e Limpeza:** Exclusão de registros com ausência completa de medições refrativas oculares e remoção de outliers de refração biologicamente implausíveis ou participantes com cirurgias oculares prévias.
3. **Tratamento de Dados Ausentes:** Aplicação de algoritmos de imputação por vizinhos mais próximos (KNN Imputer) ou imputação baseada na mediana para covariáveis que apresentem pequenas frações de dados omissos.
4. **Transformação de Atributos (Pipelines):** Codificação de raça/etnia e sexo biológico com `OneHotEncoder`. Normalização de variáveis numéricas como idade, IMC e níveis de exames bioquímicos pelo `StandardScaler` para garantir que atributos em escalas díspares não distorçam a convergência de modelos baseados em gradiente ou distância.
5. **Mitigação de Desbalanceamento:** Devido à baixa frequência relativa da classe “Alta Miopia”, o conjunto de treinamento classificatório receberá balanceamento sintético via SMOTE (da biblioteca `imbalanced-learn`), equalizando a representatividade de cada categoria e prevenindo viés nos classificadores.
6. **Treinamento de Modelos:**

- **Modelos Regressores:** Serão implementados e comparados o XGBoost Regressor, Random Forest Regressor e uma Regressão Ridge como baseline. As métricas de desempenho avaliadas serão o Erro Quadrático Médio (MSE), Erro Absoluto Médio (MAE) e o coeficiente de determinação (R^2).
- **Modelos Classificadores:** XGBoost Classifier, Random Forest Classifier e Regressão Logística Multiclasse. O desempenho será aferido através de Precision, Recall, F1-Score (macro e ponderado) e Área sob a Curva ROC (AUC-ROC) multiclasse.

4 Resultados

(construindo)

Esta seção destina-se à apresentação dos resultados empíricos gerados a partir do processamento dos dados do ciclo NHANES 2005-2006 utilizando a infraestrutura lógica descrita na metodologia. À medida que o desenvolvimento do código no repositório `NHANES_vision` progredir, serão incorporadas aqui tabelas contendo as métricas de acurácia de classificação, erros absolutos das regressões e curvas ROC comparativas dos modelos testados.

5 Discussão

(construindo)

Esta seção conterá uma análise crítica dos resultados computacionais frente às evidências científicas compiladas na fundamentação teórica. Serão discutidos o poder de predição real de covariáveis biológicas específicas (como a idade e o sexo biológico) e como as interações não lineares mapeadas por modelos de árvore (como o XGBoost) alinham-se ou divergem das descobertas clássicas encontradas em levantamentos oftalmológicos populacionais.

6 Considerações Finais

(construindo)

Neste capítulo serão apresentadas as conclusões obtidas com a conclusão do desenvolvimento do sistema inteligente, detalhando se os objetivos de diagnóstico foram atingidos de maneira satisfatória para aplicação em triagem oftalmológica em larga escala e apontando direções para trabalhos futuros no repositório.

Referências

- HARB, E. N.; WILDSOET, C. F. Nutritional Factors and Myopia: An Analysis of National Health and Nutrition Examination Survey Data. **Optometry and Vision Science**, v. 98, n. 5, p. 458-468, maio 2021.
- LEE, S. et al. Obesity and high myopia in children and adolescents: Korea National Health and Nutrition Examination Survey. **PLoS ONE**, v. 17, n. 3, p. e0265317, mar. 2022.
- LIM, D. H. et al. The high prevalence of myopia in Korean children with influence of parental refractive errors: The 2008-2012 Korean National Health and Nutrition Examination Survey. **PLoS ONE**, v. 13, n. 11, p. e0207690, nov. 2018.
- NOH, Y. H.; JUNG, K. I. The Relationship between Myopia and Obesity in Adults. **Korean Journal of Ophthalmology**, v. 38, n. 2, p. 137-146, abr. 2024.
- WOLF, A. T. et al. Association Between Serum Vitamin D Levels and Myopia in the National Health and Nutrition Examination Survey (2001-2006). **Ophthalmic Epidemiology**, v. 31, n. 3, p. 229-239, jun. 2024.
- WU, Y.-L. et al. Oxidation balance scores are positively associated with the occurrence and severity of myopia in adults: results from the National Health and Nutrition Examination Survey 2007-2008. **Molecular Vision**, v. 30, p. 422-433, dez. 2024.